



Stage de Master 2 Recherche en Informatique

Protection contre les attaques par canaux auxiliaires visant l'hyperviseur

Auteur: Georges Ouffoué

Maître de stage : Dr. Marc-Antoine LACOSTE

Organisme d'accueil : Orange Labs Issy-les-Moulineaux

Table des matières

Résumé

Post hoc impie perpetratum quod in aliis quoque iam timebatur, tamquam licentia crudelitati indulta per suspicionum nebulas aestimati quidam noxii damnabantur. quorum pars necati, alii puniti bonorum multatione actique laribus suis extorres nullo sibi relicto praeter querelas et lacrimas, stipe conlaticia victitabant, et civili iustoque imperio ad voluntatem converso cruentam, claudebantur opulentae domus et clarae.

Mots clefs

Post, impie, aliis, multatione, domus.

Introduction

Du 13 Avril au 30 Septembre 2015, nous avons réalisé un stage de recherche au sein d'Orange Labs Issy-les-Moulineaux dans le département Sécurité conformément au cahier de charges de l'Université Paris-Sud. C'est un stage de fin d'études qui permet à l'étudiant de s'imprégner des réalités de l'entreprise d'une part et d'autre part des aspects de la recherche afin de développer chez l'étudiant des aptitudes et attitudes en la matière.

1.1 Contexte et objectifs du stage

Le groupe Orange est né en 2003 suite au rachat de la société Orange par l'opérateur principal français des Télécommunications,France Télécom. Orange ,implanté actuellement dans 29 pays du monde occupe le quatrième rang mondial des sociétés de Télécommunications.Orange Labs est la branche recherche et développement du groupe. Elle mène des projets de recherche pour améliorer la qualité des services fournit par Orange et également concevoir des produits innovants. Orange place le service au cœur des enjeux d'aujourd'hui et de demain. Afin d'assurer une politique de croissance durable, le groupe Orange a mis en place des stratégies de développement. En effet, bien que le groupe Orange soit spécialisé dans les télécommunications, ces dernières années Orange a diversifié ses offres en devenant fournisseur d'accès internet, de services cloud et même d'objets connectés.

Par ailleurs, l'informatique dans les nuages ou cloud computing est un modèle informatique permettant l'accès à des ressources partagées au travers d'un réseau haut débit (Internet). Ce nouveau concept informatique a révolutionné l'industrie informatique. En effet, le cloud permet de mutualiser les ressources informatiques sur des serveurs géographiquement répartis, les utiliser à la demande et être facturés à l'utilisation. Ce qui permet de réduire les coûts de production et d'exploitation. En dépit de ces différentes facilités qu'offre le cloud, la sécurité demeure le principal frein à son adoption. Le cloud comme bien d'autres infrastructures tirant parti d'Internet, est également confronté à des attaques visant la disponibilité, l'intégrité et la confidentialité des données. Récemment, de nouvelles attaques par canaux auxiliaires ont émergé dans le cloud. Ces attaques se basent sur des mécanismes indirects de compromission tels que l'observation et la mesure de l'activité des ressources partagées (cache, disque dur) pour extirper des clés de chiffrement.

Tout fournisseur de cloud comme Orange se doit d'assurer à ses clients la sécurité de ses plateformes contre ces attaques qui deviennent de plus en plus réalistes. Face à cette situation et soucieux de la menace, Orange Labs, à travers son département sécurité dont la mission principale est de veiller à la sureté et la sécurité des contenus offerts s'évertue à rechercher des mécanismes adéquats et efficaces dans l'optique d'anticiper ces éventuelles menaces. C'est pourquoi, Orange Labs a proposé ce stage de recherche dont le thème est : «Protection contre les attaques par canaux auxiliaires visant l'hyperviseur.». Les principaux objectifs du stage sont les suivants :

- 1. L'établissement d'une cartographie des contre-mesures existantes (au niveau matériel, système, ou applicatif) et les comparer (performance, sécurité, compatibilité) avec les clouds existants);
- 2. La proposition d'une nouvelle contremesure contre ces attaques;
- 3. La validation sur des plateformes cloud.

1.2 Motivations et plan du rapport

Un parcours succinct de la littérature montre que la première étude menée sur les attaques par canaux auxiliaires dans le cloud a été réalisée dans [?]. Cette étude a montré l'effectivité de ce type d'attaque sur les plateformes actuelles de cloud. Un potentiel attaquant peut en exploitant des failles matérielles d'implémentation déployer sa machine virtuelle(VM) sur une même plateforme qu'une victime cible et dérober des informations confidentielles en examinant par exemple le trafic réseau ou les frappes de clavier. A la suite de cette attaque, plusieurs autres attaques ont été réalisées [?] et [?]. Cependant l'attaque la plus significative est celle de Zhang et al. [?] qui a permis de recouvrir la totalité d'une clé de chiffrement dans la bibliothèque de sécurité [?].

Plusieurs contremesures ont été proposées tant par des chercheurs académiques que par des chercheurs industriels permettant de se prémunir contre ces attaques. Ces moyens de lutte sont regroupés en plusieurs catégories :

- Limitations du partage du cache. Ces contremesures visent à réduire le partage du cache. Ainsi, on peut citer [?] et [?]. Un autre type de contremesures faisant partie de cette classe consiste à effectuer bruitage des données dans le cache ([?], [?]) de telle sorte que l'attaquant n'arrive pas à distinguer les données présentes dans le cache
- Contraintes de sécurité. Dans cette catégorie, on tient compte des contraintes de sécurité pendant le placement des machine virtuelles. Ainsi [?] et [?] proposent des métriques et heuristiques de placement qui permettent à des entités, respectivement, de quantifier la vulnérabilité de ces attaques et de déployer ou non leurs machines sur des mêmes environnements que des attaquants potentiels.
- Obfuscation du temps. Contrairement aux contremesures précédentes, cette contremesure vise à obfusquer la mesure du temps des attaquants. StopWatch [?] offusque le temps par la réplication des machines virtuelles en trois exemplaires et en utilisant la valeur moyenne du temps des réplicas. TimeWarp [?] quant à lui ajoute des délais aléatoires aux mesures de temps.
- Ordonnancement. Ristenpart et al. [?] ont investigué l'approche de contremesure basée sur l'ordonnancement des machines virtuelles. Avec un minimum de temps d'ordonnancement, on arrive à inhiber l'attaque.

Cependant, toutes ces contremesures ne sont spécifiques qu'à une seule couche d'abstraction de l'infrastructure cloud (couche virtuelle ou hyperviseur ou couche physique) ou à un type particulier d'application. Nous croyons qu'une meilleure sécurité nécessite d'entrevoir l'attaque dans sa globalité et non seulement à un seul niveau. De plus, nous pensons que les contremesures proposées doivent être génériques et leur exécution doit pouvoir se faire de manière autonome. Un système de sécurité autonome permet en effet, une mise en oeuvre plus flexible et plus efficiente des poliques de sécurité d'une infrastructure répartie. Nous proposons donc d'étudier et d'évaluer l'approche innovante des contremesures multicouches qui nous semble être plus sécurisante. Ainsi, les principales contributions de ce travail de recherche sont les suivantes :

- 1. La cartographie des différentes attaques par canaux auxiliaires et des contremesures existantes;
- 2. L'élaboration d'un nouvel algorithme de détection des attaques par canaux cachés auxiliaires dans le cloud;
- 3. La proposition d'un Framework autonome de protection multicouche et un benchmark de ce Framework.

Pour mener ce travail, nous présenteront d'abord dans la section suivante l'état de l'art des attaques par canaux auxiliaires et des contremesures proposées ainsi que les principaux concepts de notre étude. Dans une troisième section nous présenterons nos principales contributions. Nous évaluerons ces contributions dans la section 4 et enfin nous conclurons.

Etat de l'art

2.1 Préliminaires

2.1.1 Le cloud computing

L'expansion d'Internet a permis l'émergence du cloud computing. La définition la plus répandue et acceptée est celle du [?]. Le NIST définit le Cloud computing, comme un modèle Informatique qui permet un accès facile et à la demande par le réseau à un ensemble partagé de ressources informatiques configurables (serveurs, stockage, applications et services) qui peuvent être rapidement provisionnées et libérées par un minimum d'efforts de gestion ou d'interaction avec le fournisseur du service. D'un point de vue technique, le cloud est la réunion de plusieurs concepts informatiques dont les principaux sont le Grid computing [?] et la virtualisation. Le Grid computing permet l'agrégation des ressources distribuées. La virtualisation quant à elle assure les trois propriétés suivantes :

- Mutualisation des ressources : la virtualisation permet d'affecter les ressources d'une même machine à plusieurs applications ;
- **Abstraction de la localisation**: L'utilisateur a accès à une machine virtuelle complète qui se trouve quelque part sur un serveur, comme si elle lui était locale;
- **Elasticité** : Il est possible d'allouer des ressources supplémentaires à une application en fonction des besoins.

On distingue en outre, plusieurs types de cloud :

- Cloud privé: L'infrastructure Cloud est utilisée par une seule organisation. Elle peut être gérée par l'organisation ou par une tierce partie (Ex: OpenStack [?]);
- Cloud public : L'infrastructure Cloud est partagée par plusieurs organisations pour les besoins d'une communauté qui souhaite mettre en commun des moyens (sécurité, conformité, etc..);
- Cloud hybride : L'infrastructure Cloud est composée d'un ou plusieurs modèles ci-dessus qui restent des entités séparées.

Structurellement, trois modèles de services peuvent être offerts sur le Cloud :

- **Software-as-a-Service (SaaS)**: Ce modèle de service est caractérisé par l'utilisation d'une application partagée qui fonctionne sur une infrastructure Cloud. L'utilisateur accède à l'application par le réseau au travers de divers types de terminaux (souvent via un navigateur Web).
- Platform-as-a-Service (PaaS): l'utilisateur a la possibilité de créer et de déployer sur une infrastructure Cloud PaaS ses propres applications en utilisant les langages et les outils du fournisseur. L'utilisateur ne gère pas ou ne contrôle pas l'infrastructure Cloud sous-jacente (réseaux, serveurs, stockage) mais contrôle l'application déployée et sa configuration.
- Infrastructure-as-a-Service (IaaS) : L'utilisateur loue des moyens de calcul et de stockage, des capacités réseau et d'autres ressources indispensables (partage de charge, pare-feu, cache).
 L'utilisateur a la possibilité de déployer n'importe quel type de logiciel incluant les systèmes d'exploitation.

L'un des concepts majeurs associés au cloud est la multi-tenancy ou la possibilité d'avoir des infrastructures multi-locataires. La multi-tenancy permet à des entités d'exécuter simultanément des instances d'une même application, d'un même réseau ou d'une même plateforme. Nous nous intéressons maintenant à l'architecture des caches des processeurs qui constituent le principal vecteur d'attaque dans notre étude.

2.1.2 Architecture et fonctionnement des caches


L'avènement des nouvelles générations de processeur telles que les multi-cœurs imposent des architectures plus performantes. C'est ce qui a favorisé le concept de cache. Les caches ou mémoires cache sont des mémoires très rapides mais de faible capacité de stockage servant à stocker des données temporaires. Les caches ont été instaurés dans les architectures matérielles des processeurs afin de limiter l'impact des temps d'accès à la mémoire depuis le processeur vers la mémoire centrale et vice-versa. Les caches fonctionnent sur deux principes fondamentaux : la localité spatiale et localité temporelle. La localité spatiale est le fait que le processeur a tendance à accéder aux données proches des données accédées précédemment. La localité temporelle consiste au fait que le processeur a également tendance à accéder à une donnée accédée récemment. Le cache est divisé en blocs de même taille appelés lignes de caches contenant des blocs de lignes de mot de la mémoire centrale appeléespages. La correspondance entre les lignes de caches et les pages se fait de différentes manières. On distingue alors 3 types de caches :

- 1. Les caches à correspondance directe : Chaque page de la mémoire correspond à une unique ligne dans le cache. Cette méthode à l'avantage de permettre un accès rapide à la ligne de cache car on sait directement où elle se trouve. Cependant cette méthode s'avère peu efficace en pratique car on a souvent les mêmes données accédées tandis que les autres restent inutilisées.
- 2. Les caches associatifs: Dans ce type de cache, chaque page peut être chargée dans n'importe quelle ligne de cache. L'avantage ici c'est qu'on a un accès rapide au cache. Le principal goulot d'étranglement est la recherche d'une donnée préalablement dans le cache ce qui peut nécessiter de parcourir toutes les lignes.
- 3. Cache way-associatif : c'est un compromis entre les deux types précédents de cache. Dans ce cas, le cache est subdivisé en k blocs de taille égale appelé sets, chaque bloc comprenant un certain nombre w (way) de lignes de cache. Chaque page appartient correspond à un unique set, mais l'accès dans le set se fait de manière aléatoire. C'est ce type de cache qui est le plus utilisé dans les architectures actuelles.

Ces architectures proposent une hiérarchie de cache organisée en plusieurs niveaux. Un niveau L1 plus près de la mémoire avec un accès rapide et une taille moins importante généralement scindé en deux parties : une partie données (D), et une partie instructions (I). On a en outre le niveau L2 qui est un peu moins rapide que le niveau L1 mais plus grand en espace. Finalement, certains processeurs disposent d'un troisième niveau L3 de cache plus grand en espace mais le moins rapide. Pour chercher les données, on commence d'abord par le cache L1; dans ce cas on a un cache hit si la donnée est trouvée sinon on a un cache miss et on continue la recherche dans le cache L2 voire le cache L3 au besoin.



Figure 2.1: Architecture classique des caches



vesps.jpg






Figure 2.2: Architecture du framework Vespa [?]

2.1.3 Architecture et fonctionnement des caches

2.2 Attaques par canaux auxiliaires

2.2.1 Définition et classification

Les prouesses de la cryptographie moderne ont permis la conception d'algorithmes mathématiquement prouvés robustes et sûrs ([?], [?]). Ces algorithmes suffisent donc théoriquement pour assurer la confidentialité, l'intégrité, l'authenticité des données sensibles d'une personne ou d'une entité. Bien que ces algorithmes soient sûrs, leurs implémentations logicielles ou matérielles peuvent être sujettes à des attaques dites attaques par **canaux cachés**. Une attaque par canaux cachés utilise des moyens de communication qui normalement ne sont pas prévus pour laisser fuir les informations [?](ex. écrire et vérifier si un fichier verrouillé pour convenir un bit « 1 » ou « 0 »). On a un processus *émetteur* et un autre processus *récepteur* . L'émetteur pourrait bien être un programme malveillant préalablement installé sur le système de la victime par l'attaquant après avoir compromis ce système et le récepteur un processus non privilégié.

Une attaque par canal auxiliaire est un type particulier d'attaque par canaux cachés. Dans ce type d'attaque, Il n'y a pas de compromission des mécanismes de sécurité. En effet, ces attaques se font d'abord par l'analyse fine de la consommation électrique, de l'émanation électromagnétique ou bien du temps pendant l'exécution d'un système cryptographique. L'exploitation des résultats de la phase d'analyse rend l'attaquant capable de recouvrir des bits de clés de chiffrement de certains algorithmes. Il existe deux grandes familles d'attaques par canaux auxiliaires selon [?] : les attaques internes etles attaques externes. Dans une attaque interne, l'espion contrôle soit un processus ou une application dans un environnement partagé tel que le cloud. Ce type

d'attaques est basé sur l'analyse de l'utilisation d'une ressource matérielle partagée comme le cache des processeurs ou les disques durs. Par contre dans une attaque externe, l'attaquant réussit au préalable à posséder physiquement un système informatique avant de réaliser l'attaque.

On distingue en outre plusieurs manières d'effectuer les attaques dont certaines sont communes aux deux familles d'attaques mentionnées plus haut.Il s'agit :

- 1. Des attaques basées sur les accès aux ressources : L'attaquant inspecte l'état de la ressource partagée lorsque la victime est en fonctionnement et effectue ces analyses à la suite. Ces attaques sont le plus souvent réalisées sur les caches ou les prédicteurs de branche. Ces attaques sont les plus représentatives dans le cloud puisque cette technologie se base sur le partage de ressources.
- 2. Des attaques basées sur **le temps d'exécution**: Dans ce cas de figure, l'attaquant s'appuie sur le temps d'exécution pour compromettre le système. En effet, il exécute plusieurs fois le programme en fournissant des données différentes en entrée et à chaque exécution enregistre le temps mis. Il s'ensuit une analyse de ces temps pour inférer les clés de sécurité.
- 3. Des attaques basées sur les traces : Ce type d'attaque se base sur l'évaluation de la consommation énergétique des systèmes cryptographiques. Il s'agit en fait de mesurer le courant électrique consommé par les circuits électroniques composant ces systèmes lorsqu'ils exécutent des programmes cryptographiques. Une trace est alors un ensemble de mesures de consommation effectuées pendant le déroulement d'une opération. L'analyse des courbes obtenues et des niveaux de courant enregistrés sert à la conjecture des bits des clés. Ces attaques sont le plus souvent effectuées sur des composants embarqués comme les cartes à puces.

Par ailleurs, on trouve deux sous-classes dans cette famille [?]:

- La SPA (Simple Power Analysis) : Dans cette sous-classe, les données recueillies après la phase d'analyse sont directement exploitées et interprétées.
- La DPA (Differential Power Analysis): Ici par contre on effectue l'analyse différentielle de la consommation. En fait, on combine les résultats de la phase d'analyse avec des méthodes statistiques pour l'extraction des clés.

Ces deux sous-classes d'attaques sont facilement automatisables et ne nécessite pas la connaissance de l'architecture de la plateforme cible.

Dans le cloud la ressource matérielle la plus utilisée comme vecteur d'attaques par canaux auxiliaires est le cache. Ceci étant, notre présente étude se limitera aux attaques basées **les accès aux caches**

2.2.2 Attaques par canaux auxiliaires dans le cloud

2.2.2.1 Attaques visant les caches L1 et L2

Les attaques par canaux auxiliaires existaient bien avant l'apparition du cloud computing. Les attaques dans le cloud sont rendues possibles grâce au concept de multi-tenancy. La première étude qui a révélé la vulnérabilité des plateformes de cloud computing est [?]. L'attaque a été menée sur la plateforme de cloud public Amazon Web Services [?] avec l'hyperviseur Xen [?]. Il faut noter qu'un hyperviseur est un logiciel système qui assure le lancement, la gestion et l'approvisionnement des machines virtuelles dans une plateforme cloud. Dans le cas de l'hyperviseur XEN, on distingue une machine virtuelle particulière et privilégiée dénommée Dom0 qui agit comme orchestrateur des autres machines virtuelles et assure les fonctions de gestion. L'attaque s'est faite selon deux étapes distinctes :

- 1. la première étape a permis à l'attaquant de faire une cartographie des adress internet et lancer sa machine virtuelle(VM) sur une même plateforme physique (CPU, cœur) que la VM cible, ce qui est connu sous le terme de **co-résidence**. Deux machines virtuelles sont considérées co-résidentes si l'une des trois conditions suivantes est vérifiée :
 - Elles ont des adresses internes proches;
 - On a des latences réseau faibles entre les machines;
 - Leurs adresses correspondent en partie à l'adresse IP de Dom0;
- La seconde étape consiste à l'exploitation de la co-résidence. L'attaquant utilise pour ce faire, la méthode du PRIME TRIGGER AND PROBE qui est une variante de la méthode du PRIME AND PROBE.

Le fonctionnement de la méthode du PRIME AND PROBE [?] est le suivant :

- 1. L'attaquant remplit une ou plusieurs lignes du cache avec des données aléatoires;
- 2. Puis il laisse la main à la victime pour qu'elle puisse s'exécuter;
- 3. L'attaquant charge alors ces mêmes données dans ces mêmes lignes de cache et mesure le temps mis pour le chargement.

Le temps de chargement est parfaitement corrélé à l'accès de la victime au cache. Un temps de chargement d'une ligne de cache plus grand indique que cette ligne de cache a été accédée par la victime et ses données ont été éjectées du cache. Par contre, une faible durée montre que la partie du cache L2 concernée est restée intacte. Ces mesures ont permis de mesurer le trafic d'un serveur Web et de détermier le lien entre les pics de charge du cache et les frappes des touches du clavier. En conclusion, il faut noter que ces attaques ne sont pas assez robustes, car elles génèrent assez de faux-positifs et on ne peut qu'obtenir certaines parties des clés de chiffrement. Néanmoins cette étude, a ouvert ce domaine de recherche et a servi de tremplin aux futures attaques par canaux auxiliaires.

Ainsi, une nouvelle attaque a été montée[?]. L'attaque s'est déroulée des systèmes **SMP** (**Symetric multiprocessing**) avec l'hyperviseur Xen. Le SMP est un mode de fonctionnement particulier où tous les processeurs exécutent en parallèle le même calcul. L'hypothèse de base est que l'attaquant est incapable d'exploiter des vulnérabilités logicielles qui lui permettent de prendre contrôle de l'infrastructure physique et n'a aucune connaissance du logiciel cryptographique qu'exécute la victime. L'attaque vise à recouvrir les clés de l'algorithme de chiffrement ElGamal[?]. L'attaquant a d'abord obtenu la co-résidence avec la victime et a mesuré par la suite ,l'activité du cache L1 ,grâce à la méthode du **PRIME AND PROBE**.

Il faut noter que pour qu'une attaque par canaux auxiliaires soit réalisable, il faudrait que l'attaquant ait la possibilité de **préempter** régulièrement la victime. Lors de la mise en œuvre de la phase de mesure, l'attaquant a donc été confronté à des difficultés puisque le **multithreading** n'était pas activé. Le multithreading est la capacité de lancer plusieurs threads dans une unité de calcul (cœur par exemple) d'un processeur. Le **multithreading temporel**se fait quand les threads s'exécutent tour à tour et **le multithreading simultané** quand les threads s'exécutent simultanément. L'attaquant a réussi à contourner cet obstacle en se basant sur le comportement de l'hyperviseur Xen consistant à donner la priorité d'exécution aux **processeurs virtuels (Virtual CPU)** recevant des **interruptions**.L'attaquant peut régulièrement préempter la victime en lançant des **interruptions entre les processus**. L'étape finale est donc **la classification** des mesures de l'activité du cache et la détection des faus positifs grâce aux classificateurs utilisés dans les techniques d'apprentissage automatique (**Machine Learning**). Grâce à cette technique, l'algorithme de chiffrement Elgamal [?] a été cassé. Cette attaque est la première attaque par canaux auxiliaires dans le cloud la plus robuste avec une très fine granularité.

Une autre méthode d'attaque est la technique de l' $\mathbf{EVICT} + \mathbf{TIME}$ [?] qui s'effectue également en trois étapes :

- 1. D'abord, le programme de la victime est lancé et son temps d'exécution est mesuré;
- 2. ensuite, l'attaquant évince un set spécifique du cache;
- 3. finalement, il mesure de nouveau le temps d'exécution de la victime.

Si le temps d'exécution croit, la victime a éventuellement accédé au cache. Toutes ces attaques que nous avons présentées ne se basent que sur la mesure de l'activité des caches L1 et L2. Nous verrons donc dans ce qui suit des attaques qui exploitent les caches L3.

2.2.2.2 Attaques visant les caches L3

Les caches L3 étant les caches les moins rapides d'accès, très peu d'attaques utilisant ce cache comme vecteur d'attaque aboutissent. Une attaque ayant eu du succès est celle de Yuval et al. [?]. Les auteurs ont montré la possibilité de monter une attaque par canaux auxiliaires dans le cloud au travers du cache L3. Leur attaque tire parti de la politique déduplication de mémoire qui est une technique de partage des pages dans les architectures Intel X86 qui assure la performance en évitant la réplication de copies de même contenu et la réduction des traces de la mémoire. Elle introduit par ailleurs une nouvelle méthode d'attaque, le FLUSH AND RELOAD qui est une variante de la méthode PRIME AND PROBE. Elle nécessite que la victime et l'attaquant partagent la hiérarchie de cache, et les pages de la mémoire et doivent être co-localisées. Le fonctionnement de cette méthode se fait en trois étapes :

- 1. On évince la partie de la mémoire concernée du cache. Dans les architectures x86, l'instruction **cflush** permet de réaliser cette opération;
- 2. l'attaquant attends ensuite afin que la victime puisse accéder à la mémoire;
- 3. l'attaquant recharge la donnée à partir de la mémoire en mesurant le temps de chargement.

L'approche utilisée pour l'attaque est de tracer l'exécution du programme de la victime. L'attaquant applique la technique du **FLUSH AND RELOAD** à un espace mémoire utilisé par la victime. Pour ce faire, le temps est divisé en quantum. Dans chaque quantum de temps, l'attaquant sonde une ligne de mémoire correspondant à soit une opération d'élévation au carré, de multiplication ou de réduction conformément à l'algorithme RSA figure 3. Les séquences d'exécution dans chaque quantum indiquent le bit utilisé. Ainsi la séquence **multiplication-réduction** indique un bit positif tandis que la séquence carre-réduction un bit nul. Pour que l'attaque marche, il faudrait que la victime et l'espion s'exécutent sur le même processeur physique. Cette attaque bien que pouvant trouver jusqu'à 90% des bits, est limitée parce qu'on ne peut pas déterminer la position des bits quand des erreurs se présentent. Par ailleurs, l'attaque peut être entravée par les bruits dus aux activités d'autres processus. Comme nous l'avons signifié plus haut, cette attaque n'est possible que lorsque la déduplication de mémoire est activée. Il faut noter qu'en dépit des avantages de la déduplication, les principaux fournisseurs de cloud actuels l'ont formellement désactivée puisqu'elle induit également des failles de sécurité.

Pour montrer que les attaques par canaux auxiliaires utilisant le cache L3 sont toujours possibles sans le mécanisme de déduplication, une nouvelle approche basée sur la méthode du PRIME AND PROBE a été proposé [?]. Il faut noter qu'une attaque par la méthode du prime and probe est difficilement réalisable avec les caches L3. Selon les auteurs, les principales raisons à l'origine de cette difficulté sont la grande taille du cache et le fait que l'attaquant a une faible visibilité de l'activité de la victime puisqu'ils ne sont pas sur le même cœur. Pour finir il est également difficile de savoir les parties du cache L3 relatives à des informations sensibles.

Des moyens de contournement ont été investigués. Pour la faible visibilité de l'activité de la victime, l'inclusion des caches des caches a été activée. Le principe de ce mécanisme est que toute donnée introduite ou évincée du cache L1 est également copiée ou évincée dans les autres niveaux de caches. Ainsi l'attaquant peut remplacer la donnée dans la hiérarchie de cache sans accéder au cache de plus haut niveau. Pour le problème de la taille du cache L1, il s'agira d'effectuer uniquement la méthode du PRIME AND PROBE sur les blocs correspondant aux parties sensibles. Fort de ces mesures, une attaque a été montée contre l'algorithme de chiffrement ElGamal[?]. Elle a permis de recouvrir la totalité des clés de chiffrement avec un taux de faux positifs relativement faible.

2.2.2.3 Attaques visant les plateformes PaaS

Toutes les attaques précédentes n'étaient effectuées que sur des plateformes cloud Iaas. Zhang et al. ont montré dans [?] que les attaques par canaux auxiliaires étaient également possibles sur des plateformes Paas.

L'attaque qu'ils proposent est basée sur la méthode du FLUSH AND RELOAD vue précédemment. Le choix de cette méthode aux dépens de la méthode de PRIME AND PROBE est que le FLUSH AND RELOAD génère moins de bruit car l'attaquant est capable d'identifier clairement quand la victime a accédé à la donnée du bloc de mémoire en cours d'évaluation. Cette attaque se fait avec l'hypothèse que l'attaquant et la victime sont des utilisateurs d'une certaine plateforme Paas et l'attaquant tente de faire exécuter ses instances à l'intérieur du même conteneur que la victime pour extirper les clés de chiffrement de la victime. Un conteneur est un environnement système minimun. Un nouveau outil permettant à l'attaquant de tracer le chemin d'exécution de la victime dans les exécutables partagés a été défini.

A partir du **graphe de flot de contrôle (CFG)** du code partagé avec la victime, partage rendu possible grâce à la multi-tenancy, l'attaquant construit un automate qui permet d'inférer les différents chemins possibles que pourrait emprunter la victime. La première étape de toute attaque par canaux auxiliaires dans le cloud consiste à atteindre la co-résidence. Sur les environnements Paas, l'état de l'art actuel ne fournit aucune méthode . Les auteurs ont donc proposé une approche de détection de la co-résidence en deux étapes différentes :

- 1. le lancement plusieurs instances jusqu'à ce qu'elles aboutissent à la co-résidence;
- 2. l'utilisation de la méthode du FLUSH AND RELOAD.L'attaquant monitore un chemin d'exécution particulier découlant de l'automate construit. Si l'automate transite vers un état acceptant de l'adversaire, l'adversaire connaît donc le chemin critique de la victime.

Avec cette nouvelle méthode, l'attaquant peut réinitialiser le mot de passe d'une victime. Cette étude a donc ouvert la recherche sur la vulnérabilité des plateformes Paas aux attaques par canaux auxiliaires.

Les attaques par canaux auxiliaires dans le cloud comme nous l'avons vu dans cette section, sont indiscutablement devenues des menaces réelles pour les fournisseurs de cloud. A cet effet, plusieurs moyens de lutte ont été proposés par des chercheurs industriels et des chercheurs académiques pour contrer ces attaques. Nous les verrons en détail dans la section suivante.

2.3 Contremesures

Les attaques par canaux auxiliaires dans leur mise en œuvre, nécessitent la combinaison de plusieurs conditions : un vecteur d'attaque, une source d'attaque, et une cible d'attaque. Empêcher un de ces trois composants peut suffire à rendre l'attaque inexploitable. De ce fait, les contremesures proposées pour se prémunir contre ces attaques de par leur diversité et leur

spécificité peuvent être regroupées en plusieurs catégories. On prendra soin de préciser au niveau de quelle **couche** (**Système**, **VM**, **Hyperviseur**, **matérielle**) et qui peut mettre en œuvre ces contremesures (**Utilisateur**, **fournisseur de cloud**).

2.3.1 La réécriture des algorithmes cryptographiques

L'idée dans cette classe de contremesure consiste à **réécrire les algorithmes cryptogra- phiques** afin que l'attaquant ne puisse pas en distinguer les différentes opérations. Ainsi Yuval et al. dans [3] proposent le nouvel algorithme du listing de la figure 4 ci-dessous. Cet algorithme protège contre la méthode FLUSH AND RELOAD. L'algorithme exécute les étapes d'élévation au carré et de multiplication pour chaque bit mais ignore le résultat de la phase de multiplication pour les bits de valeur 0. Avec ce nouvel algorithme un attaquant ne peut pas discerner les différents bits puisqu'on passe par les mêmes séquences d'opération **carré-réduction-multiplication-réduction** quel que soit le bit.

Une autre approche [?] consiste à avoir une implémentation dont le temps d'exécution est constant et dans laquelle on a pas de branchements conditionnels ou des références à la mémoire correspondant aux opérations critiques. Cependant, ce type de contremesure n'est pas valable à long terme. Il a pour principale limite, le fait qu'il n'assure la protection uniquement qu'à la version courante de l'algorithme. Quand une nouvelle version est proposée, elle peut être vulnérable à un autre type d'attaque non prévu ou inconnu. Ces contremesures s'appliquent aux applications qui sont lancés dans les machines virtuelles et peuvent être implémentées par le client ou le développeur ayant lancé sa machine.

2.3.2 Isolation

Dans cette classe de contremesures, on tend à éviter au maximum la co-résidence ([?],[?],[?]) d'un attaquant et d'une victime c'est-à-dire éviter que des machines virtuelles d'entités différentes soient déployées sur la même plateforme.

Une autre approche dans ([?],[?]) vise à tenir compte des contraintes de sécurité lors du placement des VM sur les plateformes cloud. Cette contremesure assure l'isolation des différents utilisateurs et clients d'un fournisseur cloud. L'approche utilisée stipule qu'un client peut dans son placement choisir le niveau de sécurité correspondant à ses besoins.

En outre le client a la possibilité de spécifier son **type d'isolation**. C'est-à-dire qu'il a la possibilité d'être seul sur la plateforme ou de spécifier une liste d'utilisateurs avec lesquels il souhaiterait partager l'infrastructure ou finalement la liste des utilisateurs avec lesquels il n'aimerait pas être. Puisque ce problème est **NP-complet**, de nouvelles heuristiques de placement permettant de réduire la complexité ont été proposées. Il faut noter qu'expérimentalement, ces nouvelles heuristiques induisent les mêmes couts en terme de performance que les heuristiques classiques mais convergent plus rapidement que ces dernières. Cependant force est de constater que cette contremesure n'est pas facilement réalisable. Un client quelconque ne peut connaître tous les éventuels clients attaquants ou amis. Il peut arriver qu'il accepte certain utilisateurs et qu'au final ce soient des attaquants. Bien que ces contremesures soient les plus sûres, elles vont à l'encontre de l'un des objectifs du cloud computing qu'est la mutualisation des ressources pour réduire les coûts.

Par ailleurs, **HomeAlone** [?] un système qui permet à un utilisateur ou une entité de s'assurer de **son isolation**, c'est-à-dire l'exclusivité de son utilisation d'une plateforme physique. L'idée novatrice d'HomeAlone est qu'au lieu d'utiliser les attaques par canaux auxiliaires à des fins néfastes, on utilise plutôt la mise en œuvre de ces attaques comme moyen de défense. L'hypothèse de base

est que le client et le fournisseur de cloud ont un accord stipulant que le client a toute la totalité de la plateforme pour le déploiement de ces VM. HomeAlone a donc pour but de vérifier la conformité de cet accord.

Pour mener à bien leur détection, les auteurs ont utilisé la méthode du PRIME AND PROBE dans la phase de mesures et ainsi que des techniques probabilistes pour réduire le taux de zéro positifs. On décèle alors la présence d'une VM attaquant si ces probabilités sont inférieures à une valeur minimale donnée avec un taux de faux positifs très faible de 1%. HomeAlone induit moins de 5 % de surcout en termes de performance. En conclusion, bien que HomeAlone arrive à s'assurer de l'isolation, sa mise en œuvre est difficilement réalisable et elle nécessite des modifications dans le noyau des systèmes d'exploitation des clients.

2.3.3 Limitation du partage des ressources

Cette classe de contremesures vise à limiter l'accès à l'attaquant au vecteur d'attaque qu'est le cache. On a dans cette catégorie des contremesures deux sous-catégories : celle qui consiste à partitionner le cache et celle dont le but est de bruiter les données du cache.

Dans la première catégorie on peut citer la méthode du coloriage du cache [?]. C'est un mécanisme système consistant à partitionner statiquement la mémoire en des blocs distincts différenciés par un paramètre logique appelé couleur, de telle sorte que les pages ayant la même couleur correspondent à un unique ensemble de ligne de cache. On assigne alors des couleurs différentes à l'attaquant et à la victime. L'exécution de la victime est donc sécurisée. Cependant cette technique comme on peut le constater implique une faible quantité de blocs du cache utilisable pour d'autres applications; ce qui entraîne une réduction importante de la performance.

Ainsi pour rendre cette technique moins pénalisante, CHAMELEON [?], un outil de coloriage de page dynamique a été proposé. CHAMELEON dédie un ensemble de couleurs sécurisées aux VM dans les caches partagés. L'idée principale de CHAMELEON est la suivante. Lorsqu'on est en présence d'une application critique c'est-à-dire une application exécutant un calcul nécessitant la sécurité, CHAMELEON fait la coloration en choisissant un mode parmi deux modes distincts.

- 1. Le mode sélectif : Dans ce mode, c'est uniquement la partie de la mémoire correspondant au code sensible de l'application qui est assigné la couleur sécurisée. Ce qui nécessite au préalable la connaissance de cette position critique dans la mémoire. On a donc un gain en terme de performance pour une sécurité pas forcement optimale.
- 2. Le mode total : Dans ce mode, toutes les pages de la partie sensible sont assignées la couleur sécurisée. On donc une plus grande sécurité au détriment de la performance.

L'implémentation de CHAMELEON dans l'hyperviseur Xen a permis de la protection de l'algorithme AES pour un surcout de performance d'un facteur entre 2,21 et 2,23.

Plusieurs autres méthodes de partitionnement qui se basent sur le coloriage du cache ont été proposées ([?], [?]). Cependant toutes ces contremesures de coloriage de cache ont pour principal inconvénient, le fait que cette méthode entraîne des ressources supplémentaires de gestion et un le gaspillage de l'espace mémoire. Le coloriage nécessite également de connaître explicitement la structure d'indexation du cache qui très souvent n'est pas connue.

A présent nous allons nous intéresser à la seconde catégorie qui correspond aux techniques de bruitage de cache. Düppel [?], une nouvelle contremesure au niveau OS qui peut être mis en œuvre par l'utilisateur. Düppel se veut un outil qui ne nécessite pas de modifications tant au niveau des applications qu'au niveau de l'hyperviseur tout en engendrant peu de surcouts de performance. L'idée fondamentale de Düppel est de permettre à un client de brouiller ses traces d'utilisation

du cache de telle sorte que qu'un potentiel attaquant ne puisse par les exploiter à sa guise, en obfusquant les lignes de cache utilisées.

Düppel fonctionne en effectuant l'obfuscation périodique du cache entre les phases de PROBE en injectant des données aléatoires jusqu'à ce que les données de la victime soient complétement écrasées. Pour ce faire, Düppel utilise des horloges logicielles à fine résolution. Düppel génère 7% de ressources supplémentaires pour son exécution.

Cependant le principal inconvénient des méthodes de bruitage est, qu'elles peuvent drastiquement détériorer les performances des applications utilisant énormément le cache à cause du temps mis pour le bruitage et la perte de l'efficacité du cache [?].

2.3.4 Obfuscation des sources de mesure

Cette classe de contremesure a pour but de **bruiter la mesure du temps** de l'attaquant. Dans cette catégorie, on trouve **StopWatch** [?]. L'idée de base de Stopwatch est de **répliquer** les instances des machines virtuelles en trois instances différentes et prendre la valeur moyenne des temps mesurés dans chaque machine virtuelle comme la valeur de référence.

StopWatch modifie la mesure des horloges temps-réels et des horloges d'entrée-sortie. Pour obfusquer les horloges temps-réel, on utilise un temps virtuel qui est fonction des instructions réalisées effectuées auparavant par les VM. Par contre, pour les horloges d'entrée-sortie on émet plutôt des interruptions régulières.

Ainsi lorsque l'attaquant entreprendra l'analyse du cache, les temps mesurés ne seront pas les temps exacts mais des temps bruités. Il ne pourra donc pas savoir l'activité de la victime avec une fine granularité. Stopwatch génère un surcout d'un facteur 2.8 pour des applications nécessitant beaucoup d'apport en réseau. Cependant StopWatch est difficilement réalisable car sa mise en œuvre nécessite des modifications matérielles.

Une autre contremesure dans le même ordre d'idée est **TimeWarp** [?]. Le principe de Timewarp est **d'ajouter des délais aléatoires** au temps mesurés par l'attaquant lors de sa mesure du cache. Cela se fait en divisant le temps en périodes de durées aléatoires et à chaque mesure du temps ajouter deux sortes d'offset : l'offset temps réel et l'offset apparent dont les valeurs en nombre de cycles sont déterminées de façon aléatoire.

De même que pour StopWatch l'attaquant dans sa phase d'analyse n'aura pas une bonne granularité de la mesure du temps. Le surcout en termes de performance est de 4 %. Il faut noter que StopWatch nécessite également des modifications matérielles qui sont rendues possible grâce à la virtualisation. A cet jour, StopWatch n'a pas encore été envisagée dans des environnements cloud, nous proposons l'étudier dans ces environnements dans les sections suivantes.

En conclusion, les techniques d'offuscation sont les meilleures en termes de sécurité mais souffrent du fait que les architectures matérielles actuelles ne sont pas adaptées.

2.3.5 Ordonnancement des machines virtuelles

Les contremesures que nous avons vues plus haut visent soit à limiter le partage soit à bruiter la mesure du temps. Le terme **d'isolation dure** [?] est associé à cet ensemble de contremesures. De ce fait, une nouvelle approche qualifiée **d'isolation légère** qui se base sur l'ordonnancement des machines virtuelles a été envisagée [?].

Notons que pour qu'une attaque par canaux auxiliaires puisse se faire, il faudrait que la VM attaquante puisse préempter régulièrement la VM victime. Fort de ce constat, les auteurs ont investigué la relation entre les politiques d'ordonnancement des machines virtuelles dans les hyperviseurs et la protection contre les attaques par canaux auxiliaires dans le cloud.

Ils ont donc fait l'hypothèse qu'un temps minimum d'utilisation du processeur par une machine virtuelle peut contrer ces attaques. Des expériences ont montré la véracité de cette hypothèse. En effet, **un temps minimal ou Minimum Runtime Guarantee (MRT Guarantee)** de 5 ms suffisait à inhiber complètement l'attaque pour un surcout en performance relativement bas (< 4%). Cette contremesure peut être facilement déployée par un fournisseur.

Conclusion et perspectives

Cuius acerbitati uxor grave accesserat incentivum, germanitate Augusti turgida supra modum, quam Hannibaliano regi fratris filio antehac Constantinus iunxerat pater, Megaera quaedam mortalis, inflammatrix saevientis adsidua, humani cruoris avida nihil mitius quam maritus; qui paulatim eruditiores facti processu temporis ad nocendum per clandestinos versutosque rumigerulos conpertis leviter addere quaedam male suetos falsa et placentia sibi discentes, adfectati regni vel artium nefandarum calumnias insontibus adfligebant.

Remerciements

Saraceni tamen nec amici nobis umquam nec hostes optandi, ultro citroque discursantes quicquid inveniri poterat momento temporis parvi vastabant milvorum rapacium similes, qui si praedam dispexerint celsius, volatu rapiunt celeri, aut nisi impetraverint, non inmorantur.